HƯỚNG DẪN THỰC HIỆN BÀI TẬP LỚN
HỌC PHẦN NHẬP MÔN HỌC MÁY

Năm học 2026–2027

ThS. Lê Thị Thùy Trang

1 Mục tiêu của bài tập lớn

1.1 Về mặt kiến thức

Sinh viên vận dụng các kiến thức đã học trong học phần để xây dựng một quy trình học máy hoàn chỉnh, từ khám phá dữ liệu, tiền xử lý, lựa chọn đặc trưng, huấn luyện mô hình đến đánh giá và phân tích kết quả.

Sinh viên cần thể hiện được khả năng:

- Khám phá và phân tích dữ liệu (Exploratory Data Analysis – EDA), phát hiện dữ liệu thiếu, dữ liệu bất thường và các vấn đề có thể ảnh hưởng đến mô hình.
- Thực hiện các bước tiền xử lý phù hợp với từng loại dữ liệu: dữ liệu văn bản, dữ liệu ảnh hoặc dữ liệu dạng bảng.
- Lựa chọn và áp dụng các thuật toán đã học trong học phần như K-Nearest Neighbors (K-NN), Naive Bayes, Cây quyết định (Decision Tree) và K-means.
- Lựa chọn độ đo đánh giá phù hợp với bài toán phân loại, hồi quy hoặc phân cụm; phân tích kết quả thay vì chỉ báo cáo một giá trị độ chính xác.
- So sánh các phương án xử lý dữ liệu, đặc trưng hoặc mô hình và giải thích nguyên nhân dẫn đến sự khác biệt về kết quả.

Các đề tài được xây dựng trong ba nhóm ứng dụng chính:

- **Xử lý Ngôn ngữ Tự nhiên:** phân loại cảm xúc, phát hiện tin giả, lọc tin nhắn rác, phân loại chủ đề văn bản.
- **Thị giác Máy tính:** nhận dạng chữ số, nhận dạng biển báo giao thông, phân loại ảnh hoa.
- **Dữ liệu dạng bảng:** dự đoán trong giáo dục, kinh doanh, tài chính, y tế, chuỗi cung ứng và phân khúc khách hàng.

1.2 Về mặt kỹ năng

Bài tập lớn giúp sinh viên rèn luyện các kỹ năng cốt lõi của một quy trình phân tích dữ liệu và học máy:

- Tiền xử lý dữ liệu, lựa chọn đặc trưng và xây dựng pipeline học máy có thể tái tạo.
- Thiết kế thí nghiệm, thay đổi tham số và so sánh mô hình một cách có hệ thống.
- Đọc và diễn giải các chỉ số đánh giá, ma trận nhầm lẫn, biểu đồ và các trường hợp dự đoán sai.
- Làm việc nhóm, quản lý mã nguồn bằng GitHub, phân chia nhiệm vụ và theo dõi quá trình thực hiện.
- Viết báo cáo khoa học bằng LaTeX, trình bày kết quả và bảo vệ lựa chọn kỹ thuật của nhóm.

2 Yêu cầu chung

Sinh viên làm việc theo nhóm từ **2 đến 4 thành viên**. Đề tài bài tập lớn do giảng viên chỉ định theo danh sách ở Phần 3, 4 và 5 của tài liệu này.

Nhóm sử dụng đúng bộ dữ liệu được chỉ định. Trường hợp muốn thay đổi bộ dữ liệu hoặc thay đổi cách đặt bài toán, nhóm cần trao đổi và được giảng viên đồng ý trước khi thực hiện.

Các yêu cầu chung đối với sản phẩm:

- Thực hiện đầy đủ quy trình từ dữ liệu thô đến kết quả đánh giá cuối cùng; không chỉ chạy một mô hình có sẵn hoặc sao chép một notebook mẫu.
- Mỗi nhóm cần có một **phương án baseline** làm mốc so sánh, có thể là mô hình với cấu hình mặc định hoặc một cách xử lý dữ liệu đơn giản, hợp lý với bài toán.
- Với bài toán học có giám sát, nhóm cần thực hiện **ít nhất hai phương án thử nghiệm có ý nghĩa**. Ưu tiên so sánh hai thuật toán đã học khi phù hợp. Nếu đặc thù dữ liệu khiến việc áp dụng một thuật toán không hợp lý, nhóm có thể so sánh hai cách biểu diễn/tiền xử lý khác nhau nhưng phải giải thích rõ lý do.
- Với bài toán K-means, nhóm cần giải thích cách lựa chọn số cụm, đánh giá chất lượng phân cụm và mô tả ý nghĩa của các cụm thu được.
- Dữ liệu huấn luyện và dữ liệu kiểm thử phải được tách đúng quy trình. Các bước học tham số từ dữ liệu (chuẩn hóa, vector hóa, chọn đặc trưng, v.v.) phải được học trên tập huấn luyện để hạn chế *data leakage*.
- Các tham số quan trọng, cách chia dữ liệu và giá trị `random_state` (khi có) cần được ghi rõ để kết quả có thể tái tạo.
- Nhóm phải phân tích kết quả, nêu được hạn chế và các trường hợp mô hình hoạt động chưa tốt; không đánh giá mô hình chỉ dựa trên Accuracy.
- Tất cả thành viên phải hiểu và giải thích được pipeline, mã nguồn và kết quả của nhóm. Phần nội dung mà thành viên không giải thích được khi bảo vệ có thể không được công nhận trong đánh giá.

2.1 Quy trình học máy tổng quát

Quy trình thực hiện bài tập lớn tuân theo các bước tổng quát trong Hình 1.

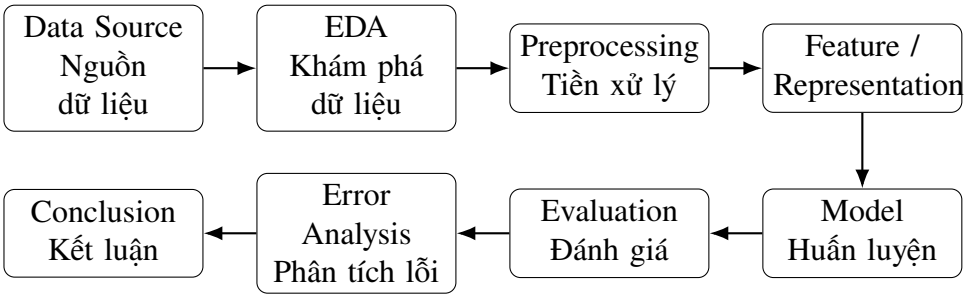


Figure 1: Sơ đồ quy trình học máy tổng quát cho bài tập lớn.

1. **Data Source – Nguồn dữ liệu**
   - Đối với bài toán xử lý ngôn ngữ tự nhiên: văn bản và nhãn.

- Đối với bài toán thị giác máy tính: ảnh và nhãn lớp.
- Đối với dữ liệu dạng bảng: các cột số, cột phân loại và biến mục tiêu; riêng bài toán phân cụm không có nhãn mục tiêu sử dụng trong quá trình huấn luyện.

2. **EDA – Khám phá và phân tích dữ liệu**
   - Kiểm tra kích thước, cấu trúc, kiểu dữ liệu, dữ liệu thiếu và dữ liệu trùng lặp.
   - Phân tích phân phối của nhãn hoặc biến mục tiêu.
   - Trực quan hóa các đặc trưng và mối quan hệ quan trọng để hình thành giả thuyết ban đầu về dữ liệu.
3. **Preprocessing – Tiền xử lý dữ liệu**
   - Văn bản: chuẩn hóa chữ thường, xử lý ký tự đặc biệt, khoảng trắng, stopword hoặc các bước chuyên biệt phù hợp với bộ dữ liệu.
   - Ảnh: resize, chuẩn hóa giá trị pixel, chuyển ảnh xám khi phù hợp.
   - Dữ liệu bảng: xử lý dữ liệu thiếu, mã hóa biến phân loại và chuẩn hóa đặc trưng số khi thuật toán yêu cầu.
4. **Feature / Representation – Biểu diễn và lựa chọn đặc trưng**
   - Văn bản: Bag-of-Words hoặc TF-IDF là các phương pháp chính; phương pháp biểu diễn nâng cao có thể được thực hiện như phần mở rộng.
   - Ảnh: sử dụng pixel sau chuẩn hóa hoặc đặc trưng cổ điển như HOG; có thể thử PCA để giảm chiều khi cần.
   - Dữ liệu bảng: lựa chọn đặc trưng phù hợp, tạo đặc trưng mới có lý giải và loại bỏ các trường thông tin gây rò rỉ nhãn nếu có.
5. **Model – Huấn luyện mô hình**
   - Lựa chọn các thuật toán đã học phù hợp với bài toán.
   - Ghi lại các siêu tham số quan trọng và thực hiện một số thử nghiệm thay đổi tham số.
   - Có thể sử dụng GridSearchCV hoặc phương pháp tương đương để hỗ trợ tìm tham số nếu nhóm giải thích được phạm vi tìm kiếm và tiêu chí lựa chọn.
6. **Evaluation and Results – Đánh giá và kết quả**
   - Phân loại: Accuracy, Precision, Recall, F1-score, Confusion Matrix; có thể bổ sung ROC-AUC nếu phù hợp.
   - Hồi quy: MAE, MSE/RMSE, R^2.
   - Phân cụm: Inertia/WCSS, Silhouette Score và phân tích đặc điểm của từng cụm.
   - Trình bày bảng và biểu đồ so sánh kết quả giữa các phương án thử nghiệm.
7. **Error Analysis – Phân tích lỗi**
   - Xác định các lớp hoặc nhóm mẫu mà mô hình thường dự đoán sai.
   - Phân tích một số trường hợp cụ thể và đưa ra giả thuyết về nguyên nhân.
   - Liên hệ kết quả với đặc điểm dữ liệu, bước tiền xử lý và giả định của thuật toán.

2.2 Nội dung báo cáo

Báo cáo bắt buộc phải gồm đầy đủ các phần sau và được trình bày theo đúng thứ tự:

1. **Đặt vấn đề và phân tích yêu cầu**
    - **Bối cảnh và mục tiêu:** giới thiệu bài toán, đối tượng cần dự đoán hoặc phân tích và ý nghĩa của bài toán.
    - **Phân tích dữ liệu (EDA):** mô tả nguồn dữ liệu, cấu trúc dữ liệu, phân phối nhãn/biến mục tiêu, dữ liệu thiếu, bất thường và các trực quan hóa cần thiết.
2. **Thiết kế giải pháp và quy trình học máy**
    - Trình bày sơ đồ hoặc mô tả pipeline của nhóm từ dữ liệu thô đến kết quả cuối cùng.
    - Mô tả các bước làm sạch, mã hóa, chuẩn hóa và lựa chọn/trích xuất đặc trưng.
    - Nêu rõ cách chia dữ liệu train/test hoặc train/validation/test và cách hạn chế data leakage.
    - Mô tả các thuật toán được lựa chọn, các tham số quan trọng và lý do lựa chọn.
3. **Phân tích mã nguồn và chức năng**
    - Mô tả cấu trúc chương trình, các notebook/module chính và chức năng của từng phần.
    - Không chèn toàn bộ mã nguồn vào báo cáo; chỉ trình bày các đoạn mã quan trọng khi cần giải thích thuật toán hoặc quy trình.
4. **Thử nghiệm và kết quả**
    - Trình bày thiết lập thí nghiệm: cách chia dữ liệu, tham số, đặc trưng sử dụng và tiêu chí đánh giá.
    - Nêu rõ phương án baseline và sử dụng baseline làm mốc khi thảo luận kết quả.
    - Lập bảng kết quả cho các mô hình/phương án khác nhau.
    - Trực quan hóa các kết quả cần thiết như Confusion Matrix, biểu đồ so sánh metric, Elbow curve hoặc biểu đồ Silhouette.
5. **Thảo luận và so sánh**
    - So sánh ưu, nhược điểm của các phương án đã thử nghiệm.
    - Phân tích tại sao một mô hình hoặc một cách tiền xử lý hoạt động tốt hơn trong bài toán cụ thể.
    - Phân tích các dự đoán sai, các lớp khó phân biệt hoặc các cụm chưa rõ ràng.
    - Nêu các hạn chế của dữ liệu và của giải pháp hiện tại.
6. **Tổng kết và hướng phát triển**
    - Tóm tắt kết quả chính của bài tập lớn.
    - Nêu hướng cải tiến có thể thực hiện nếu có thêm dữ liệu, thời gian hoặc tài nguyên tính toán.

2.3 Hình thức báo cáo và nộp bài

Sản phẩm nộp bài của mỗi nhóm gồm:

- **Báo cáo:** viết bằng LaTeX và nộp bản PDF hoàn chỉnh theo template của học phần.
- **Mã nguồn:** lưu trên repository GitHub do giảng viên chỉ định hoặc repository được thống nhất với giảng viên.

Repository tối thiểu gồm: `README.md`, mã nguồn/notebook, tệp khai báo thư viện (ví dụ `requirements.txt` hoặc `environment.yml` nếu có), thư mục báo cáo và hướng dẫn chạy chương trình. Không bắt buộc đưa các bộ dữ liệu có dung lượng lớn lên repository; nhóm ghi rõ nguồn và đường dẫn tải dữ liệu trong `README.md`.

Các thành viên cần có đóng góp thể hiện qua lịch sử commit và có khả năng giải thích phần công việc mình thực hiện khi bảo vệ bài tập lớn.

Sử dụng công cụ AI: Sinh viên được phép sử dụng các công cụ AI để hỗ trợ tìm hiểu, gợi ý mã nguồn, kiểm tra lỗi hoặc cải thiện cách trình bày. Tuy nhiên, nhóm phải chịu trách nhiệm về tính đúng đắn của nội dung, hiểu và giải thích được mã nguồn/kết quả đã nộp. Nhóm cần khai báo ngắn gọn cách đã sử dụng AI trong phụ lục báo cáo hoặc tệp `AI_USAGE.md` trong repository.

2.4 Điểm thưởng

Sinh viên có thể nhận điểm thưởng khi thực hiện tốt các nội dung mở rộng sau:

1. **GUI/ứng dụng demo:** xây dựng được giao diện hoặc ứng dụng sử dụng mô hình đã huấn luyện. Điểm cộng từ **0.5 đến 1.0 điểm** tùy mức độ hoàn thiện, tính đúng đắn và khả năng sử dụng thực tế.
2. **Khả năng tái tạo:** repository có cấu trúc rõ ràng, hướng dẫn chạy đầy đủ, khai báo môi trường/thư viện, và có thể chạy lại pipeline từ dữ liệu đến kết quả. Có thể được cộng tối đa **0.5 điểm**.
3. **Kỹ thuật mở rộng:** embeddings, PCA nâng cao, mô hình pre-trained, ensemble hoặc deployment có thể được xem xét cộng tối đa **0.5 điểm** nếu được lựa chọn có lý do, có thí nghiệm so sánh và nhóm giải thích được kết quả. Việc chỉ gọi một thư viện hoặc mô hình có sẵn mà không phân tích sẽ không được tính điểm thưởng.

Lưu ý: Điểm thưởng không thay thế các yêu cầu bắt buộc của bài tập lớn. Tổng điểm bài tập lớn sau khi cộng thưởng không vượt quá **10 điểm**.

2.5 Rubric đánh giá bài tập lớn A3

Rubric dưới đây được sử dụng để đánh giá bài tập lớn A3 và đồng thời làm căn cứ tổng hợp minh chứng cho các chỉ báo PI6.2 và PI6.3. Trong A3, PI6.2 chiếm 60% trọng số đo và PI6.3 chiếm 40% trọng số đo. Điểm của bài tập lớn được tính theo các tiêu chí có trọng số; tiêu chí về liêm chính học thuật và sử dụng AI là điều kiện/điểm trừ, không đo PI trực tiếp.

Tiêu chí / Trọng số	0–<5 Yếu	5–<7 Trung bình	7–<8 Khá	8–<9 Giỏi	9–10 Xuất sắc
Xác định bài toán, dữ liệu và nguồn dữ liệu – 10% CLO5 – PI6.2	Bài toán/dataset không rõ hoặc không phù hợp; thiếu nguồn dữ liệu.	Mô tả được bài toán và dataset nhưng mục tiêu còn chung.	Mục tiêu, dữ liệu, biến đầu vào/đầu ra rõ.	Bài toán có ý nghĩa ứng dụng; nguồn dữ liệu/giấy phép tương đối minh bạch.	Bài toán phù hợp bối cảnh, nguồn dữ liệu minh bạch, nêu rõ giả định và giới hạn.
Tiền xử lý và feature/representation – 15% CLO1, CLO5 – PI6.2	Không xử lý dữ liệu hoặc xử lý sai làm hỏng kết quả.	Có tiền xử lý cơ bản nhưng thiếu giải thích.	Pipeline preprocessing hợp lý; xử lý được lỗi chính.	Feature/representation phù hợp, có giải thích quyết định kỹ thuật.	Tiền xử lý tối ưu cho bài toán, minh chứng rõ tác động tới mô hình.
Xây dựng pipeline mô hình – 20% CLO2, CLO4, CLO5 – PI6.2	Code không chạy hoặc không có mô hình hợp lệ.	Có mô hình chạy được nhưng pipeline còn rời rạc.	Pipeline rõ: split, train, predict; mô hình chạy ổn định.	Repo/notebook tái lập tốt, cấu hình mô hình rõ.	Pipeline hoàn chỉnh, có tổ chức code tốt, dễ mở rộng/tái sử dụng.
Đánh giá và so sánh kết quả – 20% CLO3, CLO5 – PI6.3	Không có metric hoặc metric không phù hợp.	Có metric cơ bản nhưng chưa phân tích.	Metric phù hợp; có bảng/biểu đồ so sánh kết quả.	Phân tích kết quả có căn cứ, nhận diện hạn chế mô hình.	Đánh giá toàn diện, so sánh hợp lý, đề xuất cải thiện dựa trên bằng chứng.
Diễn giải kết quả và khuyến nghị ứng dụng – 15% CLO3, CLO4, CLO5 – PI6.3	Không giải thích được kết quả hoặc khuyến nghị không liên quan.	Có nhận xét mô hình ở mức mô tả.	Giải thích được metric/biểu đồ và lỗi mô hình chính.	Khuyến nghị ứng dụng/cải thiện rõ, phù hợp bối cảnh.	Diễn giải thuyết phục, khuyến nghị có căn cứ và khả năng áp dụng.
Tái lập, repo, log và quản lý nhóm – 10% CLO5 – PI6.2	Thiếu repo/log hoặc không rõ đóng góp cá nhân.	Có repo/notebook cơ bản nhưng thiếu README hoặc log.	Repo có README, log chạy và phân công nhóm.	Repo sạch, commit/log minh bạch, dễ kiểm chứng đóng góp cá nhân.	Quản lý nhóm tốt, evidence đầy đủ, cấu trúc repo chuyên nghiệp và tái lập cao.
Báo cáo, slide, demo/vấn đáp – 10% CLO5 – PI6.3	Trình bày rời rạc; demo không chạy hoặc không trả lời được.	Trình bày đủ ý chính; demo/vấn đáp còn hạn chế.	Báo cáo/slide rõ, demo được sản phẩm chính.	Trình bày mạch lạc, trả lời được câu hỏi kỹ thuật/chuyên môn.	Trình bày thuyết phục, demo ổn định, thể hiện làm chủ sản phẩm.
Liêm chính học thuật và sử dụng AI *Điều kiện/điểm trừ; không đo PI trực tiếp*	Sao chép, không khai báo nguồn/AI hoặc không giải trình được sản phẩm.	Có khai báo tối thiểu nhưng chưa đầy đủ.	Trích nguồn chính và khai báo AI ở mức chấp nhận được.	Trích nguồn, log và phân công tương đối minh bạch.	Minh bạch nguồn dữ liệu/code/prompt, giải trình nhất quán khi vấn đáp.

Cách sử dụng rubric:

- Điểm A3 được chấm theo bảy tiêu chí có trọng số, tổng trọng số bằng 100%.
- Mức mô tả trong rubric là căn cứ xác định chất lượng sản phẩm và mức độ làm chủ của nhóm; giảng viên có thể chấm điểm cụ thể trong khoảng điểm tương ứng với mức đạt được.
- Với bài toán phân cụm, các mô tả như *split/train/predict* được hiểu tương ứng theo pipeline không giám sát: chuẩn bị dữ liệu, chuẩn hóa/biểu diễn, fit mô hình, lựa chọn số cụm, đánh giá và diễn giải cụm.
- Điểm nhóm có thể được điều chỉnh ở phần trình bày/vấn đáp hoặc quản lý nhóm khi minh chứng đóng góp cá nhân và khả năng giải trình cho thấy mức độ tham gia giữa các thành viên không tương đương.
- Nếu có vi phạm liêm chính học thuật, sao chép hoặc sử dụng AI nhưng không khai báo/không giải trình được sản phẩm, giảng viên áp dụng điều kiện hoặc điểm trừ theo quy định của học phần và Nhà trường.

3 Nhóm đề tài Xử lý ngôn ngữ tự nhiên

3.1 Quy trình thực hiện chung

Đối với các đề tài thuộc nhóm xử lý ngôn ngữ tự nhiên, quy trình xây dựng dự án gồm các bước sau:

1. **Khám phá dữ liệu**
   - Kiểm tra cấu trúc dữ liệu, số lượng mẫu và các trường văn bản/nhãn.
   - Phân tích phân phối nhãn và độ dài văn bản.
   - Trực quan hóa phân phối lớp để kiểm tra mất cân bằng dữ liệu.
2. **Tiền xử lý văn bản**
   - Chuẩn hóa chữ thường khi phù hợp; xử lý dấu câu, ký tự đặc biệt và khoảng trắng thừa.
   - Xem xét stopword, chữ số, URL hoặc các thành phần đặc thù của dữ liệu.
   - Không loại bỏ thông tin một cách máy móc; nhóm cần giải thích các bước tiền xử lý có thể làm mất thông tin hữu ích.
3. **Vector hóa văn bản**
   - Thử nghiệm Bag-of-Words (CountVectorizer).
   - Thử nghiệm TF-IDF.
   - So sánh một số cấu hình như unigram/bigram, `min_df`, `max_df` hoặc số lượng đặc trưng.
   - Sentence Embeddings hoặc các biểu diễn nâng cao là phần mở rộng, không thay thế yêu cầu cốt lõi BoW/TF-IDF.
4. **Huấn luyện mô hình**
   - Multinomial Naive Bayes là mô hình phù hợp để thử nghiệm với đặc trưng đếm/TF-IDF.
   - Nhóm lựa chọn thêm ít nhất một thuật toán đã học khác khi phù hợp để thực hiện so sánh.
5. **Đánh giá và phân tích kết quả**

- Sử dụng Accuracy, Precision, Recall, F1-score và Confusion Matrix.
- Phân tích các lớp thường bị nhầm lẫn và một số văn bản mô hình dự đoán sai.
- So sánh ảnh hưởng của phương pháp vector hóa và tham số đến kết quả.

3.2 Danh sách đề tài

Đề tài 1: Phân loại cảm xúc từ phản hồi của sinh viên. Sinh viên tải tập dữ liệu tại đây.

Đề tài 2: Phát hiện tin tức giả mạo. Sinh viên tải tập dữ liệu tại đây.

Đề tài 3: Phân loại tin nhắn rác. Sinh viên tải tập dữ liệu tại đây.

Đề tài 4: Phân loại chủ đề bài báo. Sinh viên tải tập dữ liệu tại đây.

4 Nhóm đề tài Thị giác máy tính

4.1 Quy trình thực hiện chung

1. **Khám phá dữ liệu**
   - Kiểm tra cách tổ chức dữ liệu, số lượng ảnh, số lớp và phân phối nhãn.
   - Kiểm tra kích thước, số kênh màu và trực quan hóa một số ảnh mẫu của từng lớp.
2. **Tiền xử lý ảnh**
   - Resize về kích thước thống nhất và chuẩn hóa giá trị pixel.
   - Chuyển sang grayscale nếu màu sắc không phải thông tin quan trọng của bài toán.
   - Nếu sử dụng tăng cường dữ liệu, nhóm cần giải thích phép biến đổi nào hợp lý với dữ liệu và không làm thay đổi nhãn.
3. **Biểu diễn đặc trưng ảnh**
   - Baseline: vector pixel sau khi resize/normalize.
   - Thử nghiệm HOG hoặc một đặc trưng cổ điển phù hợp.
   - Có thể sử dụng PCA để giảm số chiều và phân tích ảnh hưởng tới tốc độ/hiệu năng.
   - Transfer Learning hoặc mô hình pre-trained được xem là phần mở rộng, không thay thế phần so sánh bằng các thuật toán đã học.
4. **Huấn luyện mô hình**
   - Sử dụng K-NN và/hoặc Cây quyết định trên các biểu diễn đặc trưng đã xây dựng.
   - Thử nghiệm một số giá trị tham số quan trọng như k, metric của K-NN, `max_depth` hoặc `criterion` của Cây quyết định.
5. **Đánh giá và phân tích kết quả**
   - Sử dụng Accuracy, Precision, Recall, F1-score và Confusion Matrix.
   - Phân tích lớp dễ nhầm lẫn, ảnh bị dự đoán sai và ảnh hưởng của phương pháp biểu diễn đặc trưng.

4.2 Danh sách đề tài

Đề tài 5: Nhận dạng chữ số viết tay. Sinh viên tải tập dữ liệu tại đây.

Đề tài 6: Nhận dạng biển báo giao thông. Sinh viên tải tập dữ liệu tại đây.

Đề tài 7: Phân loại hoa. Sinh viên tải tập dữ liệu tại đây.

5 Nhóm đề tài Dữ liệu dạng bảng

5.1 Quy trình thực hiện chung

Đối với các đề tài thuộc nhóm dữ liệu dạng bảng (Tabular Data), nhóm cần đặc biệt chú ý đến EDA, tiền xử lý dữ liệu, lựa chọn đặc trưng và nguy cơ rò rỉ dữ liệu.

1. **Khám phá và phân tích dữ liệu (EDA)**
   - Kiểm tra số lượng mẫu, số lượng đặc trưng, kiểu dữ liệu và ý nghĩa của từng cột.
   - Phân tích biến mục tiêu: phân phối lớp đối với phân loại hoặc phân phối giá trị đối với hồi quy.
   - Với đặc trưng số: thống kê mô tả, histogram, box plot và phát hiện ngoại lệ.
   - Với đặc trưng phân loại: tần suất các giá trị và biểu đồ cột.
   - Phân tích dữ liệu thiếu, dữ liệu trùng lặp, tương quan giữa các biến số và các cột có khả năng gây data leakage.
2. **Tiền xử lý và kỹ thuật đặc trưng**

   Sinh viên thực hiện và so sánh tối thiểu hai cấu hình xử lý dữ liệu từ cùng một dữ liệu thô.

   Luồng A: Pipeline cơ bản
   - Xử lý dữ liệu thiếu bằng phương pháp có lý giải.
   - Mã hóa đặc trưng phân loại bằng One-Hot Encoding, Ordinal Encoding hoặc phương pháp phù hợp.
   - Chuẩn hóa đặc trưng số khi cần, đặc biệt với K-NN.
   - Loại bỏ các cột định danh hoặc cột gây rò rỉ nhãn.

   Luồng B: Pipeline cải tiến
   - Thử nghiệm một lựa chọn xử lý khác đối với dữ liệu thiếu, mã hóa hoặc chuẩn hóa; hoặc
   - Lựa chọn/loại bỏ đặc trưng dựa trên phân tích dữ liệu; hoặc
   - Tạo thêm một số đặc trưng mới có ý nghĩa và giải thích giả thuyết về lợi ích của chúng.

   Mục tiêu của hai luồng là giúp nhóm trả lời câu hỏi: *thay đổi cách chuẩn bị dữ liệu có làm thay đổi hiệu quả mô hình hay không, và tại sao?*
3. **Huấn luyện mô hình**
   - Với bài toán phân loại: lựa chọn ít nhất hai thuật toán phù hợp trong K-NN, Naive Bayes và Cây quyết định.
   - Với bài toán hồi quy: có thể sử dụng KNeighborsRegressor và DecisionTreeRegressor nếu phù hợp với cách đặt bài toán.
   - Thực hiện thay đổi một số siêu tham số và ghi lại kết quả để phân tích ảnh hưởng.

4. **Đánh giá và phân tích kết quả**
    - Phân loại: Accuracy, Precision, Recall, F1-score, Confusion Matrix; với dữ liệu mất cân bằng cần ưu tiên các chỉ số phù hợp thay vì chỉ dùng Accuracy.
    - Hồi quy: MAE, RMSE và R^2.
    - Lập bảng so sánh giữa Luồng A và Luồng B, giữa các thuật toán và giữa các cấu hình tham số.
5. **So sánh và kết luận**
    - Phân tích ưu, nhược điểm của từng pipeline và mô hình.
    - Giải thích mối liên hệ giữa đặc điểm dữ liệu và kết quả mô hình.
    - Chỉ ra các trường hợp dự đoán sai quan trọng và tác động của chúng trong bối cảnh bài toán.

Lưu ý riêng cho đề tài hồi quy

Đối với Đề tài 15, sinh viên đặt bài toán theo hướng **hồi quy**, sử dụng điểm chất lượng rượu vang làm biến mục tiêu. Nhóm cần ưu tiên các độ đo MAE, RMSE và R^2, đồng thời phân tích phân phối sai số thay vì chuyển bài toán thành phân loại nếu chưa được giảng viên đồng ý.

Lưu ý riêng cho đề tài phân cụm khách hàng

Đối với Đề tài 17, sinh viên sử dụng K-means làm thuật toán chính và thực hiện:

- Lựa chọn các đặc trưng hợp lý cho phân khúc khách hàng và chuẩn hóa dữ liệu trước khi tính khoảng cách.
- Chạy K-means với nhiều giá trị k, sử dụng Elbow và Silhouette Score để hỗ trợ lựa chọn số cụm.
- Trực quan hóa kết quả khi có thể và xây dựng bảng mô tả đặc điểm của từng cụm.
- Đặt tên/diễn giải các cụm dựa trên đặc điểm dữ liệu, tránh gán ý nghĩa không được dữ liệu hỗ trợ.

5.2 Danh sách đề tài

Đề tài 8: Dự đoán sinh viên có nguy cơ bỏ học. Sinh viên tải tập dữ liệu tại đây.

Đề tài 9: Dự đoán khách hàng rời bỏ dịch vụ viễn thông. Sinh viên tải tập dữ liệu tại đây.

Đề tài 10: Dự đoán khách hàng đăng ký tiền gửi ngân hàng. Sinh viên tải tập dữ liệu tại đây.

Đề tài 11: Đánh giá rủi ro tín dụng khách hàng. Sinh viên tải tập dữ liệu tại đây.

Đề tài 12: Phát hiện giao dịch thẻ tín dụng gian lận. Sinh viên tải tập dữ liệu tại đây.

Đề tài 13: Dự đoán nhân viên có khả năng nghỉ việc. Sinh viên tải tập dữ liệu tại đây.

Đề tài 14: Dự đoán khách hàng hủy đặt phòng khách sạn. Sinh viên tải tập dữ liệu tại đây.

Đề tài 15: Dự đoán điểm chất lượng rượu vang (bài toán hồi quy). Sinh viên tải tập dữ liệu tại đây.

Đề tài 16: Dự đoán đơn hàng có nguy cơ giao trễ trong chuỗi cung ứng. Sinh viên tải tập dữ liệu tại đây.

Đề tài 17: Phân khúc khách hàng bán lẻ dựa trên đặc điểm và hành vi mua sắm. Sinh viên tải tập dữ liệu tại đây.